

Bjanka Bašić, Ivan Knezić i Jelena Lončar

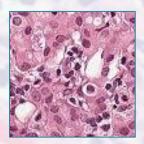
Detekcija raka na temelju histoloških preparata

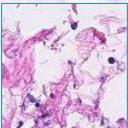
Opis problema

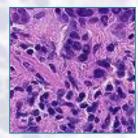
- Problem: detekcija prisutnosti metastatskog raka na temelju fotografija histoloških preparata tkiva
- Dijagnostička procedura dugotrajna je i naporna za patologe
 - potrebno ispitati veliko područje tkiva
 - malene se metastaze lako mogu previdjeti
- Svodi se na problem binarne klasifikacija oznaka klase (y)
 može poprimiti samo dvije vrijednosti
 - y=1 pozitivan primjer
 - y=0 negativan primjer
- Naš zadatak: izgraditi binarni klasifikator za prepoznavanje tumornog tkiva

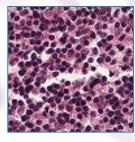
Opis podataka

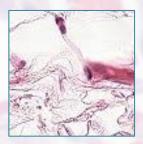
 Podaci: fotografije(96x96px) koje predstavljaju mikroskopske snimke tkiva limfnih čvorova, na koje je primjenjeno HE bojenje







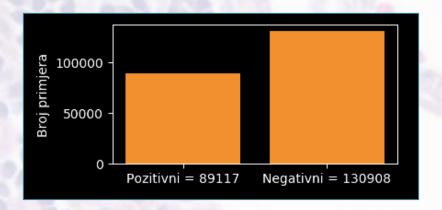




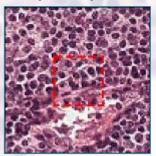
- Primjer se smatra pozitivnim primjerom ako centralno područje fotografije dimenzija 32x32px sadrži barem jedan piksel tumorskog tkiva – okolno područje ne utječe
- Skup podataka kombinacija je podatak prikupljenih:
 - Radboud University Medical Center (Nijmegen, Nizozemska)
 - University Medical Center Utrecht (Utrecht, Nizozemska)
- Koristimo verziju sa Kaggle-a ne sadrži duplikate

Eksploratorna analiza - zaključci

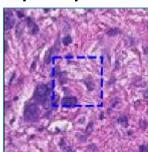
- U datasetu se nalazi: 220025 primjera za treniranje
 57458 primjera za testiranje
- Omjer negativnih i pozitivnih je 59/41



Negativni primjer

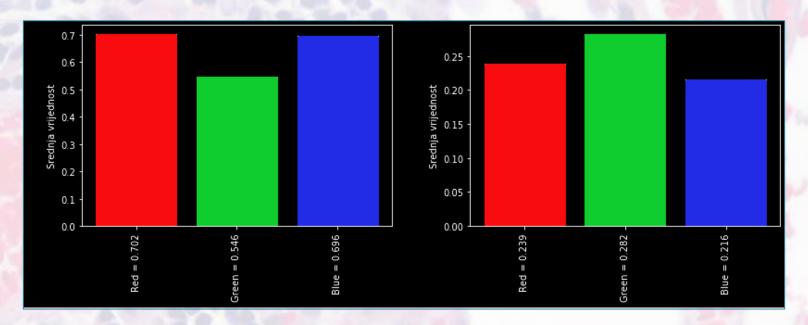


Pozitivni primjer



Eksploratorna analiza - zaključci

Statistička analiza: srednje vrijednosti pojedinih kanala boje



7 primjera presvjetlih/pretamnih slika za zaključiti nešto iz njih – zanemarivo na sveukupan broj train primjera

Cili

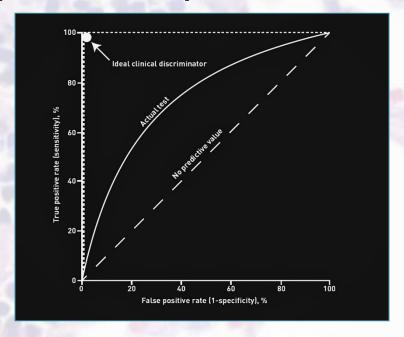
- Cilj: primjenom adekvatnih algoritama strojnog učenja postići da model bude što bolji prediktor za vrijednost ciljne varijable odgovarajućeg elementa prostora primjera
- Za dani primjer, odnosno fotografiju, odrediti što točnije je li oznaka klase:
 - y=1 na slici se nalazi barem jedan pixel tumorskog tkiva
 - y=0 na slici se ne nalazi tumorsko tkivo

Metodologija

- Problem ćemo rješavati primjenom metoda i algoritama nadziranog učenja – konvolucijske neuronske mreže (duboko učenje)
- Nastojati ćemo dobiti što uspješniji model istraživanjem raznolikih mogućnosti za arhitekture KNM te hiperparametre
- Planiramo:
 - Koristiti Python i razne biblioteke za njega:
 - Numpy, Randas, Scikit-learn, Keras, Fast.ai
 - Kao razvojno okruženje koristiti Jupyther
 - Na fotografije (primjere) primijeniti augmentacijske transformacije

Evaluacija modela

Pozitivni primjeri su nam važniji od negativnih pa ćemo evaluirati sa
 površinom ispod ROC krivulje



 Uz to još ćemo odrediti matricu konfuzije te konkretne vrijednosti osjetljivosti, preciznosti te F1-mjere

